

模式识别



第八讲 对偶支撑向量机与核支撑向量机(*Dual SVM & Kernel SVM*)



- 8.1 对偶支撑向量机动机 (*Motivation of Dual SVM*)
- 8.2 对偶支撑向量机的拉格朗日分析 (*Lagrange Dual SVM*)
- 8.3 求解对偶支撑向量机最佳值 (*Solving Dual SVM*)
- 8.4 对偶支撑向量机讨论 (*Messages behind Dual SVM*)
- 8.5 核函数支撑向量机 (*Kernel SVM*)



8.1 对偶支撑向量机动机

线性支撑向量机模型

最佳的 $(\mathbf{w}, b) = ?$

$$\begin{aligned} \min_{\mathbf{w}} \quad & \frac{1}{2} \mathbf{w}^T \mathbf{w} \\ \text{Subject to} \quad & y_n (\mathbf{w}^T \mathbf{x}_n + b) \geq 1 \\ & \text{for } n = 1, 2, \dots, N \end{aligned}$$

$$\textcircled{1} \quad \mathbf{Q} = \begin{bmatrix} 0 & \mathbf{0}_d^T \\ \mathbf{0}_d & \mathbf{I}_d \end{bmatrix}, \quad \mathbf{p} = \mathbf{0}_{d+1},$$

$$\mathbf{a}_n^T = y_n [1 \quad \mathbf{x}_n^T], \quad c_n = 1,$$

$$\textcircled{2} \quad \begin{bmatrix} b \\ \mathbf{w} \end{bmatrix} \leftarrow \text{QP}(\mathbf{Q}, \mathbf{p}, \mathbf{A}, \mathbf{c})$$

③ 返回最终的 b 和 \mathbf{w} 作为学到的 g_{SVM}

8.1 对偶支撑向量机动机

非线性支撑向量机模型

最佳的 $(\mathbf{w}, b) = ?$

$$\begin{aligned} \min_{\mathbf{w}} \quad & \frac{1}{2} \mathbf{w}^T \mathbf{w} \\ \text{Subject to} \quad & y_n (\mathbf{w}^T \underbrace{\mathbf{z}_n}_{\Phi(\mathbf{x}_n)} + b) \geq 1 \\ & \text{for } n = 1, 2, \dots, N \end{aligned}$$

$$\textcircled{1} \quad \mathbf{Q} = \begin{bmatrix} 0 & \mathbf{0}_{\tilde{d}}^T \\ \mathbf{0}_{\tilde{d}} & \mathbf{I}_{\tilde{d}} \end{bmatrix}, \quad \mathbf{p} = \mathbf{0}_{\tilde{d}+1},$$

$$\mathbf{a}_n^T = y_n [1 \quad \mathbf{x}_n^T], \quad c_n = 1,$$

$$\textcircled{2} \quad \begin{bmatrix} b \\ \mathbf{w} \end{bmatrix} \leftarrow \text{QP}(\mathbf{Q}, \mathbf{p}, \mathbf{A}, \mathbf{c})$$

③ 返回最终的 b 和 \mathbf{w} 作为学到的 g_{SVM}

如果 \tilde{d} 很大, 甚至无穷大, 挑战巨大

QP针对 $(\tilde{d} + 1)$ 个变量和 N 个约束条件求解

目的: SVM算法求解可以不依赖于 \tilde{d} 吗?



8.1 对偶支撑向量机

将有约束条件下的寻优转变为无约束条件下的寻优问题

$$\begin{aligned} \min_{\mathbf{w}} \quad & \frac{1}{2} \mathbf{w}^T \mathbf{w} \\ \text{Subject to} \quad & y_n(\mathbf{w}^T \mathbf{z}_n + b) \geq 1 \\ & \text{for } n = 1, 2, \dots, N \end{aligned}$$

用Lagrange乘子 α_n 构造Lagrange函数


$$\mathcal{L}(b, \mathbf{w}, \boldsymbol{\alpha}) = \frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{n=1}^N \alpha_n (1 - y_n(\mathbf{w}^T \mathbf{z}_n + b))$$

约束项隐含在max中


$$\text{SVM} \equiv \min_{b, \mathbf{w}} \left(\max_{\text{all } \alpha_n \geq 0} \mathcal{L}(b, \mathbf{w}, \boldsymbol{\alpha}) \right) = \min_{b, \mathbf{w}} \left(\infty \text{ if } \textit{violating}, \frac{1}{2} \mathbf{w}^T \mathbf{w} \text{ if } \textit{feasible} \right) = \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

- 任何 “*violating*” (b, \mathbf{w}) : $\max_{\text{all } \alpha_n \geq 0} \left(\blacksquare + \sum_n \alpha_n (\text{一些正数}) \right) \rightarrow \infty$
- 任何 “*feasible*” (b, \mathbf{w}) : $\max_{\text{all } \alpha_n \geq 0} \left(\blacksquare + \sum_n \alpha_n (\text{所有非正数}) \right) = \blacksquare$

第八讲 对偶支撑向量机与核支撑向量机(Dual SVM & Kernel SVM)



- 8.1 对偶支撑向量机动机 (Motivation of Dual SVM)
- 8.2 对偶支撑向量机的拉格朗日分析 (Lagrange Dual SVM)
- 8.3 求解对偶支撑向量机最佳值 (Solving Dual SVM)
- 8.4 对偶支撑向量机讨论 (Messages behind Dual SVM)
- 8.5 核函数支撑向量机 (Kernel SVM)



8.2 对偶支撑向量机的拉格朗日分析

在所有的 $\alpha_n \geq 0$ 的中挑选任意一个 α' ($\because \max \geq \text{any}$)

$$\min_{b,w} \left(\max_{\text{all } \alpha_n \geq 0} \mathcal{L}(b, w, \alpha) \right) \geq \min_{b,w} (\mathcal{L}(b, w, \alpha'))$$

如果 $\alpha' \geq 0$ 是上式右边 $\max_{\text{all } \alpha_n \geq 0} \mathcal{L}(b, w, \alpha)$ 中的最佳值 ($\because \text{best is one of any}$)

$$\min_{b,w} \left(\max_{\text{all } \alpha_n \geq 0} \mathcal{L}(b, w, \alpha) \right) \geq \underbrace{\max_{\text{all } \alpha_n \geq 0} \left(\min_{b,w} (\mathcal{L}(b, w, \alpha')) \right)}_{\text{Lagrange Dual Problem}}$$

原问题(求解 b, w)与拉格朗日对偶问题(求解 α)的关系



8.2 对偶支撑向量机的拉格朗日分析

二次规划(QP)满足强对偶特性


$$\underbrace{\min_{b,w} \left(\max_{\text{all } \alpha_n \geq 0} \mathcal{L}(b, w, \alpha) \right)}_{\substack{\text{equiv.to original SVM} \\ \text{Primal Problem}}} \geq \underbrace{\max_{\text{all } \alpha_n \geq 0} \left(\min_{b,w} (\mathcal{L}(b, w, \alpha)) \right)}_{\text{Lagrange Dual Problem}}$$

- “ \geq ”是一种弱对偶关系(weak duality)
- “ $=$ ”是一种强对偶关系(strong duality), 如果满足:

二次规划(QP)问题

- 原问题是凸函数
- 原问题存在可行解
- 约束条件为线性的

非线性变换 $\Phi(\mathbf{x}_n)$



8.2 对偶支撑向量机的拉格朗日分析

二次规划(QP)满足强对偶特性

$$\min_{b, w} \left(\max_{\text{all } \alpha_n \geq 0} \mathcal{L}(b, w, \alpha) \right) = \max_{\text{all } \alpha_n \geq 0} \left(\min_{b, w} (\mathcal{L}(b, w, \alpha)) \right)$$

equiv. to original SVM
Primal Problem
Lagrange Dual Problem


等式两边对原问题求解
和对对偶问题求解都能
得到最优 (b, w, α)

- “ \geq ”是一种弱对偶关系(weak duality)
- “ $=$ ”是一种强对偶关系(strong duality), 如果满足:

二次规划(QP)问题

- 原问题是凸函数
- 原问题存在可行解
- 约束条件为线性的

非线性变换 $\phi(x_n)$



8.2 对偶支撑向量机的拉格朗日分析


对偶问题求解

$$\max_{\text{all } \alpha_n \geq 0} \left(\min_{b, w} \left(\underbrace{\frac{1}{2} w^T w + \sum_{n=1}^N \alpha_n (1 - y_n (w^T z_n + b))}_{\mathcal{L}(b, w, \alpha)} \right) \right)$$

- “括号”内的问题(inner problem)是**无约束条件**的优化问题

$$\frac{\partial \mathcal{L}(b, w, \alpha)}{\partial b} = - \sum_{n=1}^N \alpha_n y_n = 0$$

$$\max_{\text{all } \alpha_n \geq 0, \sum_{n=1}^N \alpha_n y_n = 0} \left(\min_{b, w} \left(\frac{1}{2} w^T w + \sum_{n=1}^N \alpha_n (1 - y_n (w^T z_n)) - \sum_{n=1}^N \alpha_n y_n b \right) \right)$$



8.2 对偶支撑向量机的拉格朗日分析

对偶问题求解


$$\max_{\text{all } \alpha_n \geq 0} \left(\min_{b, \mathbf{w}} \underbrace{\left(\frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{n=1}^N \alpha_n (1 - y_n (\mathbf{w}^T \mathbf{z}_n + b)) \right)}_{\mathcal{L}(b, \mathbf{w}, \boldsymbol{\alpha})} \right)$$

- “括号”内的问题(*inner problem*)是**无约束条件**的优化问题

$$\frac{\partial \mathcal{L}(b, \mathbf{w}, \boldsymbol{\alpha})}{\partial b} = - \sum_{n=1}^N \alpha_n y_n = 0$$

“括号”内的问题**b**取最佳解时:

$$\max_{\text{all } \alpha_n \geq 0, \sum_{n=1}^N \alpha_n y_n = 0} \left(\min_{b, \mathbf{w}} \left(\frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{n=1}^N \alpha_n (1 - y_n (\mathbf{w}^T \mathbf{z}_n)) \right) \right)$$



8.2 对偶支撑向量机的拉格朗日分析

对偶问题求解


$$\max_{\text{all } \alpha_n \geq 0, \sum_{n=1}^N \alpha_n y_n = 0} \left(\min_{b, \mathbf{w}} \left(\frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{n=1}^N \alpha_n (1 - y_n (\mathbf{w}^T \mathbf{z}_n)) \right) \right)$$

- “括号”内的问题(*inner problem*)是**无约束条件**的优化问题

$$\frac{\partial \mathcal{L}(b, \mathbf{w}, \boldsymbol{\alpha})}{\partial b w_i} = w_i - \sum_{n=1}^N \alpha_n y_n z_{n,i} = 0 \quad \Rightarrow \quad \mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n$$

“括号”内的问题**w**取最佳解时:

$$\max_{\text{all } \alpha_n \geq 0, \sum_{n=1}^N \alpha_n y_n = 0, \mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n} \left(\min_{b, \mathbf{w}} \left(\frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{n=1}^N \alpha_n - \mathbf{w}^T \mathbf{w} \right) \right)$$



8.2 对偶支撑向量机的拉格朗日分析

对偶问题求解


$$\max_{\text{all } \alpha_n \geq 0, \sum_{n=1}^N \alpha_n y_n = 0} \left(\min_{b, \mathbf{w}} \left(\frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{n=1}^N \alpha_n (1 - y_n (\mathbf{w}^T \mathbf{z}_n)) \right) \right)$$

- “括号”内的问题(*inner problem*)是无约束条件的优化问题

$$\frac{\partial \mathcal{L}(b, \mathbf{w}, \boldsymbol{\alpha})}{\partial b w_i} = w_i - \sum_{n=1}^N \alpha_n y_n z_{n,i} = 0 \quad \longrightarrow \quad \mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n$$

“括号”内的问题 \mathbf{w} 取最佳解时:

$$\max_{\text{all } \alpha_n \geq 0, \sum_{n=1}^N \alpha_n y_n = 0, \mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n} \left(\min_{b, \mathbf{w}} \left(-\frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{n=1}^N \alpha_n \right) \right)$$



8.2 对偶支撑向量机的拉格朗日分析

对偶问题求解


$$\max_{\text{all } \alpha_n \geq 0, \sum_{n=1}^N \alpha_n y_n = 0} \left(\min_{b, \mathbf{w}} \left(\frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{n=1}^N \alpha_n (1 - y_n (\mathbf{w}^T \mathbf{z}_n)) \right) \right)$$

- “括号”内的问题(*inner problem*)是无约束条件的优化问题

$$\frac{\partial \mathcal{L}(b, \mathbf{w}, \boldsymbol{\alpha})}{\partial b w_i} = w_i - \sum_{n=1}^N \alpha_n y_n z_{n,i} = 0 \quad \longrightarrow \quad \mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n$$

“括号”内的问题 \mathbf{w} 取最佳解时:

$$\max_{\text{all } \alpha_n \geq 0, \sum_{n=1}^N \alpha_n y_n = 0, \mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n} \left(-\frac{1}{2} \left\| \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n \right\|^2 + \sum_{n=1}^N \alpha_n \right)$$



8.2 对偶支撑向量机的拉格朗日分析

KKT条件


$$\max_{\text{all } \alpha_n \geq 0, \sum_{n=1}^N \alpha_n y_n = 0, \mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n} \left(-\frac{1}{2} \left\| \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n \right\|^2 + \sum_{n=1}^N \alpha_n \right)$$

如果 (b, \mathbf{w}, α) 是原问题-对偶问题的最佳解 (*primal-dual optimal*):


- 原问题可行解 (*primal feasible*): $y_n(\mathbf{w}^T \mathbf{z}_n + b) \geq 1$
- 对偶问题可行解 (*dual feasible*): $\alpha_n \geq 0$
- 对偶“括号”内优化解 (*dual-inner optimal*): $\sum_{n=1}^N \alpha_n y_n = 0, \mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n$
- 原问题“括号”内优化解 (*primal-inner optimal*): $\alpha_n(1 - y_n(\mathbf{w}^T \mathbf{z}_n + b)) = 0$

----称为KKT条件，为优化的充要条件 利用对偶问题求解最佳 α 后，再用KKT条件得到 (b, \mathbf{w})

第八讲 对偶支撑向量机与核支撑向量机 (*Dual SVM & Kernel SVM*)



- 8.1 对偶支撑向量机动机 (*Motivation of Dual SVM*)
- 8.2 对偶支撑向量机的拉格朗日分析 (*Lagrange Dual SVM*)
- 8.3 求解对偶支撑向量机最佳值 (*Solving Dual SVM*)
- 8.4 对偶支撑向量机讨论 (*Messages behind Dual SVM*)
- 8.5 核函数支撑向量机 (*Kernel SVM*)



8.3 求解对偶支撑向量机最佳值

支撑向量机的对偶问题求解

$$\max_{\text{all } \alpha_n \geq 0, \sum_{n=1}^N \alpha_n y_n = 0, \mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n} \left(-\frac{1}{2} \left\| \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n \right\|^2 + \sum_{n=1}^N \alpha_n \right)$$

标准的硬间隔SVM的对偶问题----求解最佳 α :

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N \alpha_n \alpha_m y_n y_m \mathbf{z}_n^T \mathbf{z}_m - \sum_{n=1}^N \alpha_n \\ \text{Subject to} \quad & \sum_{n=1}^N \alpha_n y_n = 0 \\ & \alpha_n \geq 0, \text{ for } n = 1, 2, \dots, N \end{aligned}$$

- α 的目标函数是二次函数、凸函数! N 个变量
- α 的约束条件是线性函数! $N+1$ 个约束条件

----二次规划(QP)问题!

QP有成熟方便的办法求优化解!

8.3 求解对偶支撑向量机最佳值



SVM对偶问题的一般求解:

二次规划(QP)的求解:

最佳的 α =?

最佳的 $\mathbf{u} \leftarrow \text{QP}(\mathbf{Q}, \mathbf{p}, \mathbf{A}, \mathbf{c})$

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N \alpha_n \alpha_m y_n y_m \mathbf{z}_n^T \mathbf{z}_m - \sum_{n=1}^N \alpha_n \\ \text{Subject to} \quad & \sum_{n=1}^N \alpha_n y_n = 0 \\ & \alpha_n \geq 0, \text{ for } n = 1, 2, \dots, N \end{aligned}$$

$$\begin{aligned} \min_{\mathbf{u}} \quad & \frac{1}{2} \mathbf{u}^T \mathbf{Q} \mathbf{u} + \mathbf{p}^T \mathbf{u} \\ \text{Subject to} \quad & \mathbf{a}_m^T \mathbf{u} \geq c_m \\ & \text{for } m = 1, 2, \dots, M \end{aligned}$$

$$\mathbf{u} = [\alpha_1 \quad \dots \quad \alpha_n \quad \dots \quad \alpha_N]^T \quad \mathbf{p} = -\mathbf{1}_N$$

$$\mathbf{Q} = \begin{bmatrix} y_1 y_1 \mathbf{z}_1^T \mathbf{z}_1 & \dots & y_1 y_N \mathbf{z}_1^T \mathbf{z}_N \\ \vdots & & \vdots \\ y_N y_1 \mathbf{z}_N^T \mathbf{z}_1 & \dots & y_N y_N \mathbf{z}_N^T \mathbf{z}_N \end{bmatrix}$$

$$\mathbf{a}_{\geq}^T = [y_1 \quad \dots \quad y_n \quad \dots \quad y_N], \quad c_{\geq} = 0$$

$$\mathbf{a}_{\leq}^T = [-y_1 \quad \dots \quad -y_n \quad \dots \quad -y_N], \quad c_{\leq} = 0$$

$$\mathbf{a}_1^T = [1 \quad \dots \quad 0 \quad \dots \quad 0],$$

$$\mathbf{a}_n^T = [0 \quad \dots \quad 1 \quad \dots \quad 0], \quad c_n = 0, \quad M = N$$

$$\mathbf{a}_N^T = [0 \quad \dots \quad 0 \quad \dots \quad 1],$$



8.3 求解对偶支撑向量机最佳值

利用二次规划(QP)实现支撑向量机对偶问题求解

$$\textcircled{1} \quad \mathbf{Q} = \begin{bmatrix} y_1 y_1 \mathbf{z}_1^T \mathbf{z}_1 & \cdots & y_1 y_N \mathbf{z}_1^T \mathbf{z}_N \\ \vdots & y_n y_m \mathbf{z}_n^T \mathbf{z}_m & \vdots \\ y_N y_1 \mathbf{z}_N^T \mathbf{z}_1 & \cdots & y_N y_N \mathbf{z}_N^T \mathbf{z}_N \end{bmatrix}, \quad \mathbf{p} = -\mathbf{1}_N,$$

$$\mathbf{a}_n^T = [0 \quad \cdots \quad 1 \quad \cdots \quad 0], \quad c_n = 0,$$


$$\mathbf{a}_{\geq}^T = [y_1 \quad \cdots \quad y_n \quad \cdots \quad y_N], \quad c_{\geq} = 0,$$

$$\mathbf{a}_{\leq}^T = [-y_1 \quad \cdots \quad -y_n \quad \cdots \quad -y_N], \quad c_{\leq} = 0,$$

$$\textcircled{2} \quad [\alpha_1 \quad \cdots \quad \alpha_n \quad \cdots \quad \alpha_N]^T \leftarrow \text{QP}(\mathbf{Q}, \mathbf{p}, \mathbf{A}, \mathbf{c})$$

③ 返回最终的 α

8.3 求解对偶支撑向量机最佳值



求解最佳的 (b, \mathbf{w})


如果 (b, \mathbf{w}, α) 是原问题-对偶问题的最佳解(*primal-dual optimal*):

- 原问题可行解(*primal feasible*): $y_n(\mathbf{w}^T \mathbf{z}_n + b) \geq 1$
- 对偶问题可行解(*dual feasible*): $\alpha_n \geq 0$
- 对偶“括号”内优化解(*dual-inner optimal*): $\sum_{n=1}^N \alpha_n y_n = 0, \mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n$
- 原问题“括号”内优化解(*primal-inner optimal*): $\alpha_n(1 - y_n(\mathbf{w}^T \mathbf{z}_n + b)) = 0$

----称为KKT条件，为优化的充要条件


挑选任意一个 $\alpha_n > 0$ 的样本， $b = y_n - \mathbf{w}^T \mathbf{z}_n$ $\alpha_n > 0$ 的样本是支撑向量

第八讲 对偶支撑向量机与核支撑向量机(Dual SVM & Kernel SVM)




- 8.1 对偶支撑向量机动机 (Motivation of Dual SVM)
- 8.2 对偶支撑向量机的拉格朗日分析 (Lagrange Dual SVM)
- 8.3 求解对偶支撑向量机最佳值 (Solving Dual SVM)
- 8.4 对偶支撑向量机讨论 (Messages behind Dual SVM)
- 8.5 核函数支撑向量机 (Kernel SVM)

7.3 支撑向量机



为什么叫支撑向量机?



$$\mathbf{X} = \begin{bmatrix} 0 & 0 \\ 2 & 2 \\ 2 & 0 \\ 3 & 0 \end{bmatrix} \quad \mathbf{y} = \begin{bmatrix} -1 \\ -1 \\ +1 \\ +1 \end{bmatrix}$$

$$\min_{\mathbf{w}} \quad \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

$$\text{Subject to} \quad y_n(\mathbf{w}^T \mathbf{x}_n + b) \geq 1, \text{ for all } n$$

优化得到的解为:


$$w_1 = 1, w_2 = -1, b = -1$$

$$g(\mathbf{x}) = \text{sign}(x_1 - x_2 - 1)$$

$$\text{margin}(\mathbf{w}) = \frac{1}{\|\mathbf{w}\|} = \frac{1}{\sqrt{2}}$$

- 分类面由边界上的样本确定, 其他样本不起作用
- 边界上的样本被称为支撑向量(候选)

支撑向量机(SVM)—Support Vector Machine
----借助支撑向量学到间隔最大分类面



8.4 对偶支撑向量机讨论

SVM原问题


- 分类面由边界上的样本确定，其他样本不起作用
- 边界上的样本被称为支撑向量(候选)

SVM对偶问题

- $\alpha_n > 0$ 的样本落在分类面的边界上
- $\alpha_n > 0$ 的样本 (z_n, y_n) 被称为支撑向量(候选)
- $SV(\alpha_n > 0 \text{ 的样本}) \subseteq SV(\text{边界上的样本})$

求解 w 时，只需要支撑向量: $w = \sum_{n=1}^N \alpha_n y_n z_n = \sum_{SV} \alpha_n y_n z_n$

求解 b 时，只需要任一个支撑向量 (z_n, y_n) : $b = y_n - w^T z_n$



SVM

----利用对偶问题的最佳解确定支撑向量，从而找到间隔最大的分类面



8.4 对偶支撑向量机讨论

SVM:

$$w_{SVM} = \sum_{n=1}^N \alpha_n (y_n z_n)$$

α_n 由对偶问题的解确定

PLA:

$$w_{PLA} = \sum_{n=1}^N \beta_n (y_n z_n)$$

β_n 由分错的样本确定


w 是 $y_n z_n$ 的线性组合

w 被数据 $y_n z_n$ 所表达

w 体现出“模式”

SVM: 仅通过SV表达 w





8.4 对偶支撑向量机讨论

SVM的原问题求解:

$$\begin{aligned} \min_{\mathbf{w}} \quad & \frac{1}{2} \mathbf{w}^T \mathbf{w} \\ \text{Subject to} \quad & y_n(\mathbf{w}^T \mathbf{z}_n + b) \geq 1 \\ & \text{for } n = 1, 2, \dots, N \end{aligned}$$

- $(\tilde{d} + 1)$ 个变量和 N 个约束条件
- 求解最佳 (b, \mathbf{w})

SVM的对偶问题求解:

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N \alpha_n \alpha_m y_n y_m \mathbf{z}_n^T \mathbf{z}_m - \sum_{n=1}^N \alpha_n \\ \text{Subject to} \quad & \sum_{n=1}^N \alpha_n y_n = 0 \\ & \alpha_n \geq 0, \text{ for } n = 1, 2, \dots, N \end{aligned}$$


- N 个变量和 $N+1$ 个约束条件
- 求解最佳 α , 确定支撑向量

两种方法都能得到最佳解 (b, \mathbf{w}) 获得最大间隔分类面 $g_{SVM} = \text{sign}(\mathbf{w}^T \phi(\mathbf{x}_n) + b)$

第八讲 对偶支撑向量机与核支撑向量机(Dual SVM & Kernel SVM)



- 8.1 对偶支撑向量机动机 (Motivation of Dual SVM)
- 8.2 对偶支撑向量机的拉格朗日分析 (Lagrange Dual SVM)
- 8.3 求解对偶支撑向量机最佳值 (Solving Dual SVM)
- 8.4 对偶支撑向量机讨论 (Messages behind Dual SVM)
- 8.5 核函数支撑向量机 (Kernel SVM)




8.5 核函数支撑向量机

研究对偶SVM的动机是不想依赖 \tilde{d}

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N \alpha_n \alpha_m y_n y_m \mathbf{z}_n^T \mathbf{z}_m - \sum_{n=1}^N \alpha_n \\ \text{Subject to} \quad & \sum_{n=1}^N \alpha_n y_n = 0 \\ & \alpha_n \geq 0, \text{ for } n = 1, 2, \dots, N \end{aligned}$$

8.5 核函数支撑向量机



研究对偶SVM的动机是不想依赖 \tilde{d}


$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \alpha^T \mathbf{Q} \alpha - \mathbf{1}^T \alpha \\ \text{Subject to} \quad & \mathbf{y}^T \alpha = 0 \\ & \alpha_n \geq 0, \text{ for } n = 1, 2, \dots, N \end{aligned}$$

$$\mathbf{Q} = \begin{bmatrix} y_1 y_1 \mathbf{z}_1^T \mathbf{z}_1 & \cdots & y_1 y_N \mathbf{z}_1^T \mathbf{z}_N \\ \vdots & y_n y_m \mathbf{z}_n^T \mathbf{z}_m & \vdots \\ y_N y_1 \mathbf{z}_N^T \mathbf{z}_1 & \cdots & y_N y_N \mathbf{z}_N^T \mathbf{z}_N \end{bmatrix}$$

对偶SVM真的不依赖于 \tilde{d} ?

- N 个变量和 $N+1$ 个约束条件
- 对偶问题的 \mathbf{Q} 是个稠密矩阵
- 每个元素 $q_{n,m} = y_n y_m \mathbf{z}_n^T \mathbf{z}_m$ 都要做内积运算，计算代价 $O(\tilde{d})$

能提高 $\mathbf{z}_n^T \mathbf{z}_m = \Phi(\mathbf{x}_n)^T \Phi(\mathbf{x}_m)$ 计算效率吗?



8.5 核函数支撑向量机


二次多项式 $\Phi_2(\mathbf{x})$ 的快速内积计算

$$\Phi_2(\mathbf{x}) = (1, x_1, x_2, \dots, x_d, x_1^2, x_1x_2, \dots, x_1x_d, x_2x_1, x_2^2, \dots, x_2x_d, x_dx_1, x_dx_2, \dots, x_d^2)$$

$$\begin{aligned}\Phi_2^T(\mathbf{x})\Phi_2(\mathbf{x}') &= 1 + \sum_{i=1}^d x_i x'_i + \sum_{i=1}^d \sum_{j=1}^d x_i x_j x'_i x'_j \\ &= 1 + \sum_{i=1}^d x_i x'_i + \sum_{i=1}^d x_i x'_i \sum_{j=1}^d x_j x'_j \\ &= 1 + \mathbf{x}^T \mathbf{x}' + (\mathbf{x}^T \mathbf{x}')(\mathbf{x}^T \mathbf{x}')\end{aligned}$$

计算复杂度从 $O(\tilde{d})$ 下降到 $O(d)$

8.5 核函数支撑向量机



核函数: Φ 变换+内积计算 $\longrightarrow K_\Phi(\mathbf{x}, \mathbf{x}') = \Phi^T(\mathbf{x})\Phi(\mathbf{x}')$


$$K_{\Phi_2}(\mathbf{x}, \mathbf{x}') = \Phi_2^T(\mathbf{x})\Phi_2(\mathbf{x}') = 1 + \mathbf{x}^T \mathbf{x}' + (\mathbf{x}^T \mathbf{x}')(\mathbf{x}^T \mathbf{x}')$$

$$q_{n,m} = y_n y_m \mathbf{z}_n^T \mathbf{z}_m = y_n y_m \Phi^T(\mathbf{x}_n) \Phi(\mathbf{x}_m) = y_n y_m K_\Phi(\mathbf{x}_n, \mathbf{x}_m)$$

$$\mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n = \sum_{SV} \alpha_n y_n \mathbf{z}_n$$

$$\text{支撑SV}(\mathbf{z}_m, y_m): b = y_m - \mathbf{w}^T \mathbf{z}_m = y_m - \left(\sum_{SV} \alpha_n y_n \mathbf{z}_n \right)^T \mathbf{z}_m$$

$$\text{输入测试样本 } \mathbf{x}: g_{SVM} = \text{sign}(\mathbf{w}^T \Phi(\mathbf{x}) + b)$$



8.5 核函数支撑向量机

核函数: Φ 变换+内积计算 $\longrightarrow K_{\Phi}(\mathbf{x}, \mathbf{x}') = \Phi^T(\mathbf{x})\Phi(\mathbf{x}')$


$$K_{\Phi_2}(\mathbf{x}, \mathbf{x}') = \Phi_2^T(\mathbf{x})\Phi_2(\mathbf{x}') = 1 + \mathbf{x}^T \mathbf{x}' + (\mathbf{x}^T \mathbf{x}')(\mathbf{x}^T \mathbf{x}')$$

$$q_{n,m} = y_n y_m \mathbf{z}_n^T \mathbf{z}_m = y_n y_m \Phi^T(\mathbf{x}_n) \Phi(\mathbf{x}_m) = y_n y_m K_{\Phi}(\mathbf{x}_n, \mathbf{x}_m)$$

$$\mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n = \sum_{SV} \alpha_n y_n \mathbf{z}_n$$

$$\text{支撑SV}(\mathbf{z}_m, y_m): b = y_m - \mathbf{w}^T \mathbf{z}_m = y_m - \sum_{SV} \alpha_n y_n \Phi^T(\mathbf{x}_n) \Phi(\mathbf{x}_m)$$

$$\text{输入测试样本 } \mathbf{x}: g_{SVM} = \text{sign}(\mathbf{w}^T \Phi(\mathbf{x}) + b)$$



8.5 核函数支撑向量机

核函数: Φ 变换+内积计算 $\longrightarrow K_{\Phi}(\mathbf{x}, \mathbf{x}') = \Phi^T(\mathbf{x})\Phi(\mathbf{x}')$


$$K_{\Phi_2}(\mathbf{x}, \mathbf{x}') = \Phi_2^T(\mathbf{x})\Phi_2(\mathbf{x}') = 1 + \mathbf{x}^T \mathbf{x}' + (\mathbf{x}^T \mathbf{x}')(\mathbf{x}^T \mathbf{x}')$$

$$q_{n,m} = y_n y_m \mathbf{z}_n^T \mathbf{z}_m = y_n y_m \Phi^T(\mathbf{x}_n) \Phi(\mathbf{x}_m) = y_n y_m K_{\Phi}(\mathbf{x}_n, \mathbf{x}_m)$$

$$\mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n = \sum_{SV} \alpha_n y_n \mathbf{z}_n$$

$$\text{支撑SV}(\mathbf{z}_m, y_m): b = y_m - \mathbf{w}^T \mathbf{z}_m = y_m - \sum_{SV} \alpha_n y_n K_{\Phi}(\mathbf{x}_n, \mathbf{x}_m)$$

$$\text{输入测试样本 } \mathbf{x}: g_{SVM} = \text{sign}(\mathbf{w}^T \Phi(\mathbf{x}) + b) = \text{sign}\left(\left(\sum_{SV} \alpha_n y_n \mathbf{z}_n\right)^T \Phi(\mathbf{x}) + b\right)$$



8.5 核函数支撑向量机

核函数: Φ 变换+内积计算 $\longrightarrow K_{\Phi}(\mathbf{x}, \mathbf{x}') = \Phi^T(\mathbf{x})\Phi(\mathbf{x}')$


$$K_{\Phi_2}(\mathbf{x}, \mathbf{x}') = \Phi_2^T(\mathbf{x})\Phi_2(\mathbf{x}') = 1 + \mathbf{x}^T \mathbf{x}' + (\mathbf{x}^T \mathbf{x}')(\mathbf{x}^T \mathbf{x}')$$

$$q_{n,m} = y_n y_m \mathbf{z}_n^T \mathbf{z}_m = y_n y_m \Phi^T(\mathbf{x}_n) \Phi(\mathbf{x}_m) = y_n y_m K_{\Phi}(\mathbf{x}_n, \mathbf{x}_m)$$

$$\mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n = \sum_{SV} \alpha_n y_n \mathbf{z}_n$$

$$\text{支撑SV}(\mathbf{z}_m, y_m): b = y_m - \mathbf{w}^T \mathbf{z}_m = y_m - \sum_{SV} \alpha_n y_n K_{\Phi}(\mathbf{x}_n, \mathbf{x}_m)$$

$$\text{输入测试样本 } \mathbf{x}: g_{SVM} = \text{sign}(\mathbf{w}^T \Phi(\mathbf{x}) + b) = \text{sign}\left(\sum_{SV} \alpha_n y_n \Phi^T(\mathbf{x}_n) \Phi(\mathbf{x}) + b\right)$$



8.5 核函数支撑向量机

核函数: Φ 变换+内积计算 $\longrightarrow K_{\Phi}(\mathbf{x}, \mathbf{x}') = \Phi^T(\mathbf{x})\Phi(\mathbf{x}')$

$$K_{\Phi_2}(\mathbf{x}, \mathbf{x}') = \Phi_2^T(\mathbf{x})\Phi_2(\mathbf{x}') = 1 + \mathbf{x}^T \mathbf{x}' + (\mathbf{x}^T \mathbf{x}')(\mathbf{x}^T \mathbf{x}')$$

$$q_{n,m} = y_n y_m \mathbf{z}_n^T \mathbf{z}_m = y_n y_m \Phi^T(\mathbf{x}_n) \Phi(\mathbf{x}_m) = y_n y_m K_{\Phi}(\mathbf{x}_n, \mathbf{x}_m)$$

$$\mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{z}_n = \sum_{SV} \alpha_n y_n \mathbf{z}_n$$

$$\text{支撑SV}(\mathbf{z}_m, y_m): b = y_m - \mathbf{w}^T \mathbf{z}_m = y_m - \sum_{SV} \alpha_n y_n K_{\Phi}(\mathbf{x}_n, \mathbf{x}_m)$$

$$\text{输入测试样本 } \mathbf{x}: g_{SVM} = \text{sign}(\mathbf{w}^T \Phi(\mathbf{x}) + b) = \text{sign}\left(\sum_{SV} \alpha_n y_n K_{\Phi}(\mathbf{x}_n, \mathbf{x}) + b\right)$$

利用核函数, 将
计算复杂度从
 $O(\tilde{d})$ 下降到 $O(d)$
避免依赖 \tilde{d}




8.5 核函数支撑向量机

利用二次规划(QP)实现核函数支撑向量机求解

- ① $q_{n,m} = y_n y_m K_\phi(\mathbf{x}_n, \mathbf{x}_m)$, $\mathbf{p} = -\mathbf{1}_N$, 由约束条件得到 (\mathbf{A}, \mathbf{c})
- ② $\alpha \leftarrow \text{QP}(\mathbf{Q}, \mathbf{p}, \mathbf{A}, \mathbf{c})$
- ③ 任选一支撑SV (\mathbf{x}_m, y_m) : $b \leftarrow (y_m - \sum_{SV} \alpha_n y_n K_\phi(\mathbf{x}_n, \mathbf{x}_m))$
- ④ 对于测试样本 \mathbf{x} : $g_{SVM} = \text{sign}(\sum_{SV} \alpha_n y_n K_\phi(\mathbf{x}_n, \mathbf{x}) + b)$

- 步骤①的时间复杂度: $O(N^2) \cdot (\text{kernel evaluation})$
- 步骤②的开销 : N 个变量, $N + 1$ 个约束
- 步骤③和④的复杂度: $O(\#SV) \cdot (\text{kernel evaluation})$



8.5 核函数支撑向量机

二次多项式核函数的一般表达式

$\Phi_2(\mathbf{x})$	$K_2(\mathbf{x}, \mathbf{x}')$
$(1, x_1, \dots, x_d, x_1^2, x_1 x_2, \dots, x_d^2)$	$1 + \mathbf{x}^T \mathbf{x}' + (\mathbf{x}^T \mathbf{x}')^2$
$(1, \sqrt{2}x_1, \dots, \sqrt{2}x_d, x_1^2, x_1 x_2, \dots, x_d^2)$	$1 + 2\mathbf{x}^T \mathbf{x}' + (\mathbf{x}^T \mathbf{x}')^2$
$(1, \sqrt{2\gamma}x_1, \dots, \sqrt{2\gamma}x_d, x_1^2, x_1 x_2, \dots, x_d^2)$	$1 + 2\gamma \mathbf{x}^T \mathbf{x}' + \gamma^2 (\mathbf{x}^T \mathbf{x}')^2$

$$K_2(\mathbf{x}, \mathbf{x}') = (1 + \gamma \mathbf{x}^T \mathbf{x}')^2 \quad \gamma > 0$$


不同的二次多项式变换:

- 升维次数相同
- 内积结果不同 \longrightarrow 分类面不同




8.5 核函数支撑向量机


二次多项式核函数的一般表达式



$$(1 + 0.001 \mathbf{x}^T \mathbf{x}')^2$$



$$1 + \mathbf{x}^T \mathbf{x}' + (\mathbf{x}^T \mathbf{x}')^2$$



$$(1 + 1000 \mathbf{x}^T \mathbf{x}')^2$$

- 核函数不同 \longrightarrow 支撑向量(SVs)不同, 分类面(g_{SVM})不同
- 核函数变化 \longrightarrow Margin也会变化

8.5 核函数支撑向量机



多项式核函数的一般表达式


$$K_2(\mathbf{x}, \mathbf{x}') = (\zeta + \gamma \mathbf{x}^T \mathbf{x}')^2 \quad \gamma > 0, \zeta \geq 0$$

$$K_3(\mathbf{x}, \mathbf{x}') = (\zeta + \gamma \mathbf{x}^T \mathbf{x}')^3 \quad \gamma > 0, \zeta \geq 0$$

\vdots


$$K_Q(\mathbf{x}, \mathbf{x}') = (\zeta + \gamma \mathbf{x}^T \mathbf{x}')^Q \quad \gamma > 0, \zeta \geq 0$$

- Q 、 γ 、 ζ 确定了多项式核函数的形式
- 利用核函数可不依赖于 \tilde{d} 获得大间隔分类面



Margin为1的10次多项式

SVM + Polynomial Kernel
= Polynomial SVM



8.5 核函数支撑向量机

核函数能实现无穷维变换?

当 $\phi(\mathbf{x})$ 为无穷维变换时, 借助核函数 $K(\mathbf{x}, \mathbf{x}')$ 技巧仍可进行有效计算

为简单起见, 考虑一维变量, 即: $\mathbf{x} = (x)$

$$\begin{aligned}
 K(x, x') &= \exp(-(x - x')^2) = \exp(-(x)^2) \exp(-(x')^2) \exp(2xx') \\
 &= \exp(-(x)^2) \exp(-(x')^2) \left(\sum_{i=0}^{\infty} \frac{(2xx')^i}{i!} \right) \\
 &= \sum_{i=0}^{\infty} (\exp(-(x)^2) \exp(-(x')^2) \sqrt{\frac{2^i}{i!}} \sqrt{\frac{2^i}{i!}} (x)^i (x')^i) \\
 \Phi(x) &= \exp(-(x)^2) \cdot (1, \sqrt{\frac{2^1}{1!}} x, \sqrt{\frac{2^2}{2!}} x^2, \sqrt{\frac{2^3}{3!}} x^3, \dots, \dots)
 \end{aligned}$$

人工智能与自动化学院

39



8.5 核函数支撑向量机

核函数能实现无穷维变换?

当 $\phi(\mathbf{x})$ 为无穷维变换时, 借助核函数 $K(\mathbf{x}, \mathbf{x}')$ 技巧仍可进行有效计算

为简单起见, 考虑一维变量, 即: $\mathbf{x} = (x)$


$$\begin{aligned}
 K(x, x') &= \phi(x)^T \phi(x') = \exp(-(x - x')^2) = \exp(-(x)^2) \exp(-(x')^2) \exp(2xx') \\
 &= \exp(-(x)^2) \exp(-(x')^2) \left(\sum_{i=0}^{\infty} \frac{(2xx')^i}{i!} \right) \\
 &= \sum_{i=0}^{\infty} (\exp(-(x)^2) \exp(-(x')^2) \sqrt{\frac{2^i}{i!}} \sqrt{\frac{2^i}{i!}} (x)^i (x')^i) \\
 \Phi(x) &= \exp(-(x)^2) \cdot (1, \sqrt{\frac{2^1}{1!}} x, \sqrt{\frac{2^2}{2!}} x^2, \sqrt{\frac{2^3}{3!}} x^3, \dots, \dots)
 \end{aligned}$$

高斯核函数 $K(\mathbf{x}, \mathbf{x}')$ 的一般式

$$\begin{aligned}
 K(\mathbf{x}, \mathbf{x}') &= \exp(-\gamma \|\mathbf{x} - \mathbf{x}'\|^2) \\
 \gamma &> 0
 \end{aligned}$$

人工智能与自动化学院

40



8.5 核函数支撑向量机

高斯核函数SVM

$$K(\mathbf{x}, \mathbf{x}') = \exp(-\gamma \|\mathbf{x} - \mathbf{x}'\|^2) \quad \gamma > 0$$

输入测试样本 \mathbf{x} :
$$g_{SVM} = \text{sign}\left(\sum_{SV} \alpha_n y_n K_{\phi}(\mathbf{x}_n, \mathbf{x}) + b\right)$$

$$= \text{sign}\left(\sum_{SV} \alpha_n y_n \exp(-\gamma \|\mathbf{x} - \mathbf{x}_n\|^2) + b\right)$$

- 以所有支撑向量 \mathbf{x}_n 为中心的高斯函数的线性组合
- 也被称之为**径向基核函数**(Radial Basis Function, RBF)

高斯核函数SVM: 通过求取 α_n 确定所有支撑向量 \mathbf{x}_n , 构造以支撑向量为中心的高斯函数的线性组合, 实现在无穷维空间获得最大间隔分类面

第八讲 对偶支撑向量机与核支撑向量机(Dual SVM & Kernel SVM)



8.1 对偶支撑向量机动机(Motivation of Dual SVM)

希望不依赖于非线性变换后升维的 $\tilde{\mathbf{d}}$

8.2 对偶支撑向量机的拉格朗日分析(Lagrange Dual SVM)

通过**KKT**条件将原问题和对偶问题相关联获得最佳分类面

8.3 求解对偶支撑向量机最佳值(Solving Dual SVM)

仍然是二次规划问题, 可以方便求解

8.4 对偶支撑向量机讨论(Messages behind Dual SVM)

由支撑向量确定最大间隔分类面

8.5 核函数支撑向量机(Kernel SVM)

利用核函数避免了对升维后 $\tilde{\mathbf{d}}$ 的依赖, 且高效求解